

DriveVLA-W0：创新点、算法与数学公式

ICLR 2026 · 2026-09-16 · 按新提示词重制版

阅读包：2026-09-16_ICLR2026_DriveVLA-W0_阅读包。完整原文与逐段译文位于 ZIP；本 PDF 集中呈现 13 项学习简报、创新点对比、实现级算法、公式、固定源码链接与证据边界。

用未来图像预测补足动作监督过稀的问题，再以 500M 动作专家降低控制延迟。本材料重制 2026-09-16 的历史阅读包，不是新推荐。

完整 13 项学习简报

1. 基本信息

Yingyan Li、Shuyao Shang、Weisong Liu 等；中国科学院自动化研究所与引望智能。ICLR 2026。阅读和翻译选定 arXiv:2510.12796v2 (22 页，含附录)；ICLR 正式入口。官方仓库 BraveGroup/DriveVLA-W0，固定 commit a55766ce46ee55d9035b93816e57b8d933166482。VQ 路线基于 Emu3 8B，ViT 路线基于 Qwen2.5-VL 7B，动作专家约 500M。

2. 分类标签

自动驾驶 VLA · 世界模型 · 自回归视觉 token · 潜在扩散 · MoE 动作专家 · 流匹配 · 数据规模定律。

3. 个性化学习理由

你的 Qwen2.5-VL LoRA/SFT 经历能直接映射到 ViT 世界模型；VGGT、Depth Pro、YOLO 项目可提供几何和动态目标表征。本文补足的是如何用未来视觉监督迫使驾驶 VLA 学到环境动力学，以及如何把大模型表征交给低延迟连续动作头。

4. 一句话问题定义

大 VLA 只用少量路径点监督时，如何获得足够密集的学习信号、随数据规模持续提升，并在实时预算内输出动作？

5. 方法流程

历史语言、视觉与动作组成交错序列→Emu3 离散视觉 token 或 Qwen2.5-VL 连续特征→第一阶段联合动作预测和未来图像预测→第二阶段接入动作专家，VLA 与动作专家逐层联合注意力→查询式、AR 或流匹配解码轨迹。详见算法 1 至算法 3 与公式章节。

6. 真正创新点

真正贡献是把未来图像生成作为驾驶 VLA 的密集自监督目标，并在 VQ、ViT 两类骨干上分别实现；同时用并行 MoE 动作专家研究解码器随数据规模的性能反转。Emu3、Qwen2.5-VL、MoVQGAN、潜在扩散、FAST tokenizer、flow matching 均为沿用模块。下方对比表给出瓶颈、修改和证据。

7. 实验与证据

论文报告：NAVSIM v1 单前视相机版本最高 93.0 PDMS (AR expert+best-of-6)；查询式单轨迹为 88.4。NAVSIM v2 为 86.1 EPDMS。70M 帧时，VQ 世界模型 ADE 改善 28.8%，ViT 世界模型碰撞率改善 15.9%；动作专家从小数据的 Query 领先反转为 70M 上 AR 最佳。MoE Query 延迟 74.3 ms，对比基线 117.8 ms，为 63.1%。源码静态分析：已读取固定 commit；公开代码确认交错标签、扩散噪声目标、联合 Q/K/V、流匹配和 KV cache。实际运行验证：仅进行独立公式/形状小样例及阅读包离线验收；未下载 checkpoint、NuPlan/NAVSIM 或运行 GPU 评测，不能称已复现。

8. 局限与适用范围

内部 70M 数据、64 GPU 训练和 100 个挑战场景不能公开完整复现；仓库明确只开放经审核部分。世界模型可能生成逼真但遗漏安全关键对象的未来，附录给出对向车漏预测；粗粒度导航命令在 Y 路口有歧义。生成保真度与规划的相关性不等于因果充分性。Flow matching 在大数据不收敛的结论与该实现、训练预算相关。公开训练脚本含作者机器绝对路径，必须改配置。论文未设独立 Limitations/Ethics 章节。

9. 前置知识（5 项）

① 因果语言模型与 token mask；② VQ/MoVQGAN；③ DDPM 潜在扩散与 ϵ/v prediction；④ MoE 联合注意力和 KV cache；⑤ flow matching 的插值路径、速度目标和 ODE Euler 积分。

10. 55 分钟学习路线

0 – 10 分钟：图 1、摘要、监督不足；10 – 22 分钟：第 3.1 – 3.2 节和式（1） – （3）；22 – 36 分钟：第 3.3 节与 Joint Attention；36 – 46 分钟：表 3、4 分析数据规模；46 – 55 分钟：对照源码写出两个阶段的梯度路径与几何世界模型实验。

11. 代码学习任务

先读数据标签如何只保留视觉/动作 token，再读 Qwen 世界模型如何从 t 帧特征预测 t+1 潜变量；随后跟踪 Emu3Pi0 中 [VLA token；动作 token] 的联合 Q/K/V 和 10 步流匹配。官方 README 给出的训练需求为 $8\times L20$ 40GB、约 16 小时；这是公开 NAVSIM 流程说明，不代表完整 70M 实验。固定链接在下方算法小节。

12. 两个面试问题

Q1：为什么未来图像预测比只加更多动作数据更可能解决监督不足？答：每帧图像/潜变量提供高维密集目标，并要求表征保留对象、几何和动态；仅路径点仍把复杂场景压成少量数。但视觉 loss 也可能学外观捷径，必须用动作条件和规划指标验证。

Q2：为什么小数据上 Flow/Query 更强，大数据上 AR 反超？答：小数据轨迹分布较简单，连续解码无量化误差；复杂分布下，AR 的 token 条件分解、teacher forcing 和建模容量更易扩展。论文表 4 是实证，不能提升为所有任务的普遍定理。

13. 迁移实验

在 Qwen2.5-VL 路线加入冻结的 VGGT/Depth Pro 几何 token：以相邻两帧预测未来深度、可见性与 RGB latent，多任务 loss 与动作 loss 联合；YOLO 目标转换为带深度、速度和置信度的对象 token。做 RGB-only、RGB+深度、RGB+深度但打乱时序、RGB+真实动作/反事实动作四组；同数据量、训练步、优化器，按 NAVSIM NC/TTC/EP、未来深度误差、目标召回和延迟比较。若未来图像更清晰但动态对象召回或 NC 下降，应拒绝“世界理解更强”的结论。

创新点对比：旧方法、修改、作用与证据

旧方法/模块	输入输出与瓶颈	本文改动和原因	监督/复杂度与代价	论文证据
仅动作 VLA	高维图像→少量路径点/token；容量受稀疏监督约束	同时预测未来视觉场景，保留动态与几何信息	训练增加视觉生成成本；驾驶推理跳过世界模型生成	表 3 的 70M 增益；表 7 跨动作分布泛化
LAW 潜在预测/纯视频预训练	潜在目标较间接，或没有动作条件	VQ 路线预测视觉 token；ViT 路线预测未来图像 latent，并输入动作特征	视觉目标更密集；可能偏重外观与生成保真度	表 5：6V 84.1→6VA 85.6 PDMS；表 8 FID 与 PDMS 正相关
大 VLA 直接解码动作	每个动作 token 都经过 7B/8B 骨干，延迟高	500M 动作专家与 VLA 专家逐层联合注意力，专门产生动作	增加小专家参数；Query/Flow 延迟与 token 长度近似无关	117.8→74.3 ms, PDMS 85.6→88.4
固定一种动作头	忽视分布复杂度随数据规模改变	同一 MoE 平台比较 Query、AR、Flow	Query 精确但有容量瓶颈；AR 有量化和串行成本；Flow 需多步且样本效率较低	表 4：103k Query 最佳；70M AR 的 ADE/碰撞最佳

算法 1：双路线世界模型联合训练

1. 问题与衔接：把稀疏动作监督补成密集预测目标。VQ 输入为交错 L/V/A token；ViT 输入为 Qwen 特征，目标是下一帧 VAE latent。
2. 形状：B 批量，H 历史步，N 视觉 token 数，M 动作 token 数，C 隐藏维， $z \in \mathbb{R}^{[B,C_z,H_z,W_z]}$ 。VQ 序列 $S=[L,V,A,\dots]$ ；ViT 条件视觉特征重排为 [B,C,10,18]，动作特征平均后为 [B,C]；未来 latent 约 [B,C_z,H_z,W_z]，准确尺寸由 VAE/输入决定。
3. 预处理/掩码：语言使用原 tokenizer，路径点由 FAST 离散化。数据代码把非目标 token 的 label 置 -100；纯视觉设置只保留视觉范围。ViT 代码断言每样本两帧，取 t 的 image/action hidden，VAE 在 no_grad 中编码 t+1；扩散时间 k 均匀采样。
4. 训练/梯度：VQ 交叉熵梯度回到完整 VLA。ViT 总 loss 是基础 action loss+ross_loss；VAE 冻结，UNet requires_grad=True，视觉/动作条件从 VLA hidden 进入 denoiser，所以世界 loss 可回传至 VLA。第一阶段联合训练；第二阶段论文说明骨干不冻结但只收动作专家 loss。
5. 推理：驾驶时跳过视觉生成；可视化才 AR 生成 token 并用 MoVQGAN 解码，或运行扩散反向过程。
6. 小例：视觉 token 真值概率 [0.8,0.5]， $\text{AR loss} = -\ln 0.8 - \ln 0.5 \approx 0.9163$ ；action loss=0.4、 $\alpha=0.5$ ，总 loss=0.8582。扩散单元 $\epsilon=0.6$ 、预测 0.4，MSE=0.04； $\beta=0.5$ 时给总 loss 增 0.02。
7. 自行编写示意伪代码（不是作者原代码）：

8. 源码：标签与视觉 loss mask · utils/datasets.py:264-335； $t \rightarrow t+1$ 、冻结 VAE、联合 loss · reference/Qwen2.5-VL/qwen2_5_vl/modeling_qwen2_5_vl_ross.py:334-370；噪声、时间步、 ϵ/v 目标 · reference/Qwen2.5-VL/qwen2_5_vl/modeling_ross/denoiser_sd.py:64-117。

9. 差异：论文给 β 权重，公开 ViT 包装器直接把 ross_loss.mean 加到基础 loss，未显式乘 β ；denoiser 同时支持 epsilon/v_prediction。公开代码只覆盖审核部分，不能据此重建完整 70M 训练。

算法 2：动作专家的 Joint Attention

1. 问题：让小动作专家读取大 VLA 表征，同时减少完整骨干逐 token 解码的延迟。
2. 形状：VLA hidden [B,L_v,C_v]、动作 hidden [B,L_a,C_a]；各自投影为 Q [B,h,L,d]、K/V [B,h_kv,L,d]。沿序列维拼成总长度 L_v+L_a，注意力输出再拆回两个专家。
3. 前向/掩码：VLA Q/K 使用 RoPE，动作专家 Q/K 不使用；repeat_kv 后调用 scaled_dot_product_attention。VLA 内部 causal+padding；动作部分可双向或因果。Flow 路径中动作专家只能看第二个 BOA 之前的 VLA 内容；推理预计算并缓存 VLA K/V。
4. 训练/梯度：联合注意力没有 detach，动作 loss 通过 VLA 的 K/V 回到骨干；论文第二阶段不冻结 VLA。每个专家保持自己的 MLP、norm 和投影，注意力输出按序列拆分。
5. 推理：VLA context 算一次；Flow 的 10 步复用 VLA K/V，仅重复动作专家路径。AR 按 token 长度串行，Query 单前向。
6. 手算：一个 VLA key 和一个 action key 的 logits=[0,ln3]，softmax=[.25,.75]；value=[2,6] 时动作 query 输出 5。若 mask 禁止未来动作 key，其权重归零。
7. 自行编写示意伪代码：

8. 源码：联合 Q/K/V 与拆分 · [reference/Emu3/emu3/mlm/modeling_emu3.py:1760-1850](#)；因果与可见性 mask · [reference/Emu3/emu3/mlm/modeling_emu3.py:2580-2668](#)；KV cache 和流匹配采样 · [reference/Emu3/emu3/mlm/modeling_emu3.py:2370-2433](#)。
9. 误区：这是两个专家在每层共享一次注意力运算，不是路由器从专家池里 top-k 选专家；不能直接套用稀疏路由复杂度结论。

算法 3：Flow Matching 动作生成

1. 问题：从噪声连续生成 8 帧、每帧 3 维的轨迹，避免离散 token 量化。
2. 形状：真实动作 x 、噪声 z_1 、插值 z_t 和速度预测均 $[B,8,3]$ ； $t=[B]$ 广播为 $[B,1,1]$ 。另有历史动作与命令组成的 state token。
3. 采样/前向： t 默认从 $s \cdot (1 - \text{Beta}(1.5,1.0))$ 采样， $s=.999$ ； $z_t=(1-t)x+tz_1$ 。动作 projector 把 z_t 与 t embedding 转为 token，经 Joint Attention，decoder 预测速度。
4. 训练/梯度：目标速度 $z_1 - x$ ，MSE 更新动作专家、decoder 和未冻结 VLA。脚本 `freeze_vlm=False`、`action_sample_steps=10`；公开实现 `action_loss_weight=1`、`vlm_loss_weight=0`。
5. 推理：从 $t=1$ 噪声开始， $dt=-1/S$ ， S 默认 10；每步 $z \leftarrow z+dt \cdot v$ ，直到 0。缓存 VLA K/V；无 classifier-free guidance。
6. 小例： $x=2$ 、 $z_1=-1$ 、 $t=.25$ ，则 $z_t=1.25$ ，目标 $v=-3$ 。若模型准确且 $dt=-.1$ ，一步 z 变为 1.55；沿反向时间累计从 -1 回到 2。
7. 自行编写示意伪代码：

8. 源码： t 分布与直线插值 · [models/policy_head/noise_schedulers.py:4-62](#)；训练前向与速度 loss · [reference/Emu3/emu3/mlm/modeling_emu3.py:2038-2129](#)；10 步 Euler · [reference/Emu3/emu3/mlm/modeling_emu3.py:2394-2433](#)；训练配置 · [scripts/scripts_train/train_navsim_flow_matching.sh:1-70](#)。
9. 方向：公开实现 $t=0$ 是数据、 $t=1$ 是噪声，故训练目标 $\text{noise} - \text{action}$ ，推理用负 dt 反向积分；理解符号方向必须同时看插值与积分。

关键数学公式逐式解释

式（1）：动作自回归交叉熵

$$L_{\text{Action}} = - \sum_i \mathbb{1}^M \log P(a_i | S_{-t}, a_{<i}). \quad (1)$$

a_i 是动作 token， M 为 token 数， S_t 为多模态上下文。右边逐 token 取真实类别的负对数概率；teacher forcing 使训练并行，推理仍串行。真值概率 $[.8,.5]$ 时 $\text{loss}=.9163$ 。梯度提高真实 token logit。相比连续 L1，它能表达复杂条件分布但有量化误差。对应 AR action loss · [reference/Emu3/emu3/mlm/modeling_emu3.py:3472-3514](#)。

式（2）：AR 世界模型

$$L_{\text{WM-AR}} = - \sum_i \mathbb{1}^N \log P(v_i | S_{<V}, v_{<i}). \quad (2)$$

v_i 是离散视觉 token， N 为视觉 token 数， S 含此前语言、视觉和动作。计算与式（1）相同，但 label mask 只保留目标视觉位置。两 token 概率 $[.9,.25]$ 时 $\text{loss} \approx 1.4917$ 。它提供密集监督，但受 codebook 量化并可能偏重纹理。总 VQ 目标为 $L_{\text{Action}} + \alpha L_{\text{WM-AR}}$ ； α 控制两类梯度。

式（3）：扩散世界模型 MSE

$$\mathcal{L}_{\text{WM-Diff}} = \mathbb{E}_{z \sim p(z|t, \epsilon, k)} [\epsilon - \hat{\epsilon}(z, t, k, F^{\text{V}}, F^{\text{A}})]^2. \quad (3)$$

$z_{t+1} \in \mathbb{R}^{[B, C_z, H_z, W_z]}$ 是下一帧 latent, ϵ 同形高斯, $k=[B]$ 为时间步; $F_t^{\text{V}}/F_t^{\text{A}}$ 是当前视觉/动作条件。先冻结 VAE 编码下一帧, 再加噪预测目标。 $\epsilon=.6$ 、预测 .4 时误差 .04, 梯度为 $-.4$ 。MSE 适合高斯扩散且避免视觉词表; 代价是 UNet/VAE。若 scheduler 为 `v_prediction`, 代码把目标切换为 velocity; 总 ViT 目标为 $\mathcal{L}_{\text{Action}} + \beta \mathcal{L}_{\text{WM-Diff}}$ 。

式 (4) : Joint Attention 拼接

$$Q=[Q_{\text{VLA}};Q_{\text{AE}}], K=[K_{\text{VLA}};K_{\text{AE}}], V=[V_{\text{VLA}};V_{\text{AE}}]. \quad (4)$$

分号为 token 维拼接。 $Q_{\text{VLA}}=[B, h, L_v, d]$ 、 $Q_{\text{AE}}=[B, h, L_a, d]$, 结果 $[B, h, L_v+L_a, d]$; 注意力矩阵为 $[B, h, L_v+L_a, L_v+L_a]$, 再拆回专家。mask 控制动作能否看见未来。拼接让动作 loss 更新 VLA 表征; 简单串接网络则交互更浅。

补充解释式：Flow Matching

$$z_t = (1-t)x + t\epsilon, u_t = \epsilon - x, \mathcal{L}_{\text{FM}} = \mathbb{E} \|v_\phi(z_t, t, c) - u\|^2.$$

这是公开代码的实现展开, 不冒充论文编号。 $x, \epsilon, z_t, u_t \in \mathbb{R}^{[B, 8, 3]}$; c 为上下文。 $t=0$ 是数据、 $t=1$ 是噪声; 速度沿直线恒为 $\epsilon - x$ 。例 $x=2, \epsilon=-1, u=-3$; 推理 $dt=-.1$, 更新量 $+.3$, 朝数据移动。它比一次 L1 更能表达条件连续分布, 但要多次调用网络。

评价公式：PDMS/EPDMS

$$\text{PDMS} = \text{NC} \cdot \text{DAC} \cdot \frac{5\text{EP} + 5\text{TTC} + 2\text{C12}}{16}.$$

NC、DAC 是乘法门控; EP/TTC 权重各 5, 舒适度权重 2。NC=.98、DAC=.96、EP=.82、TTC=.95、C=1 时 PDMS≈78.4。该指标不可微, 只用于评估。EPDMS 再乘 DDC/TLC, 分子增加 2LK+2HC+2EC, 分母 16; 版本间分数不可直接横比。评估由外部 NAVSIM 仓库执行, 当前仓库只提供调用脚本。

源码覆盖与证据边界

固定源码链接由页面脚本生成为包含 commit 的 GitHub permalink。静态分析覆盖公开数据标签、Qwen 扩散世界模型、Emu3 Joint Attention、三种动作专家入口及训练/推理脚本。仓库声明只开放审核通过部分; 没有可完整重建内部 70M 实验的公开数据与全套配置。本次未运行模型, 只完成本地文件、公式、相对路径、页面切换、PDF 页数与 ZIP 完整性检查。